

ARISA Learning Material

Educational Profile and EQF level: DATA SCIENTIST – EQF 6

PLO: 1, 2, 3, 4, 5

Learning Unit (LU): MACHINE LEARNING: SUPERVISED

Topic: 7. MODEL SELECTION



www aiskills er

Copyright © 2024 by the Artificial Intelligence Skills Alliance

All learning materials (including Intellectual Property Rights) generated in the framework of the ARISA project are made freely available to the public under an open license Creative Commons Attribution—NonCommercial (CC BY-NC 4.0).

ARISA Learning Material 2024

This material is a draft version and is subject to change after review coordinated by the European Education and Culture Executive Agency (EACEA).

Authors: Universidad Internacional de La Rioja (UNIR)

Disclaimer: This learning material has been developed under the Erasmus+ project ARISA (Artificial Intelligence Skills Alliance) which aims to skill, upskill, and reskill individuals into high-demand software roles across the EU.



This project has been funded with support from the European Commission. The material reflects the views only of the author, and the Commission cannot be held responsible for any use which may be made of the information contained therein.



About ARISA

- The Artificial Intelligence Skills Alliance (ARISA) is a four-year transnational project funded under the EU's Erasmus+ programme. It delivers a strategic approach to sectoral cooperation on the development of Artificial Intelligence (AI) skills in Europe.
- ARISA fast-tracks the upskilling and reskilling of employees, job seekers, business leaders, and policymakers into Al-related professions to open Europe to new business opportunities.
- ARISA regroups leading ICT representative bodies, education and training providers, qualification regulatory bodies, and a broad selection of stakeholders and social partners across the industry.

ARISA Partners & Associated Partners | LinkedIn | Twitter



OPTIMIZACIÓN DE PARÁMETROS

Representación:

Extraer y
seleccionar
características de
objetos



Entrenar modelos:

Ajustar el
estimador a los
datos



Refinamiento

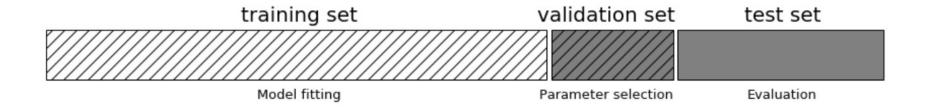
de
características
y modelos





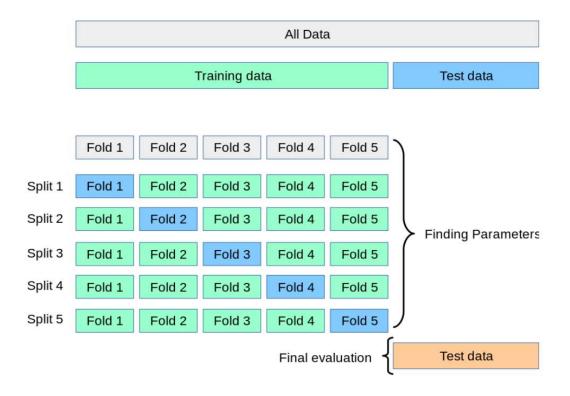
EVALUACIÓN Y REFINAMIENTO DE MODELOS

Threefold split





Cross-validation + test set





```
X_trainval, X_test, y_trainval, y_test = train_test_split(X, y)
X train, X val, y train, y val = train test split(X trainval, y trainval)
val scores = []
 neighbors = np.arange(1, 15, 2)
for i in neighbors:
    knn = KNeighborsClassifier(n_neighbors=i)
    knn.fit(X train, y train)
    val scores.append(knn.score(X val, y val))
 print("best validation score: {:.3f}".format(np.max(val scores)))
 best n neighbors = neighbors[np.argmax(val scores)]
 print("best n neighbors:", best n neighbors)
 knn = KNeighborsClassifier(n neighbors=best n neighbors)
 knn.fit(X trainval, y trainval)
 print("test-set score: {:.3f}".format(knn.score(X_test, y_test)))
best validation score: 0.991
```

best n neighbors: 11 test-set score: 0.951



Grid-Search con validacion cruzada

```
from sklearn.model_selection import cross_val_score

X_train, X_test, y_train, y_test = train_test_split(X, y)
cross_val_scores = []

for i in neighbors:
    knn = KNeighborsClassifier(n_neighbors=i)
    scores = cross_val_score(knn, X_train, y_train, cv=10)
    cross_val_scores.append(np.mean(scores))

print("best cross-validation score: {:.3f}".format(np.max(cross_val_scores)))
best_n_neighbors = neighbors[np.argmax(cross_val_scores)]
print("best n_neighbors:", best_n_neighbors)
knn = KNeighborsClassifier(n_neighbors=best_n_neighbors)
knn.fit(X_train, y_train)
print("test-set score: {:.3f}".format(knn.score(X_test, y_test)))
```

best cross-validation score: 0.967 best n_neighbors: 9 test-set score: 0.965



GridSearchCV

```
from sklearn.model_selection import GridSearchCV

X_train, X_test, y_train, y_test = train_test_split(X, y, stratify=y)

param_grid = {'n_neighbors': np.arange(1, 15, 2)}

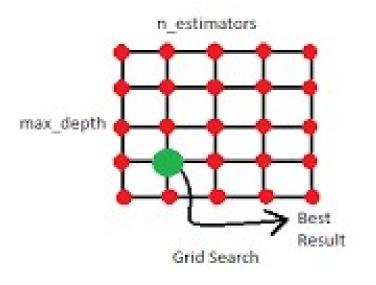
grid = GridSearchCV(KNeighborsClassifier(), param_grid=param_grid, cv=10)
 grid.fit(X_train, y_train)

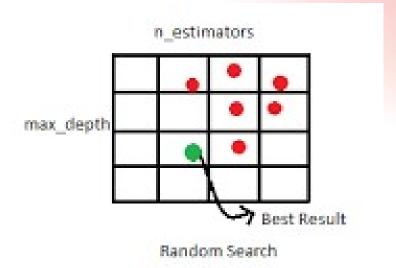
print("best mean cross-validation score: {:.3f}".format(grid.best_score_))
 print("best parameters:", grid.best_params_)

print("test-set score: {:.3f}".format(grid.score(X_test, y_test)))
```

best mean cross-validation score: 0.967
best parameters: {'n_neighbors': 9}
test-set score: 0.993









Parámetros de búsqueda de cuadrícula (Grid Search Parameters)

```
sklearn.model_selection.GridSearchCV(estimator, param_grid,scoring=None, n_jobs=None, iid='deprecated', refit=True, cv=None, verbose=0, pre_dispatch='2*n_jobs', error_score=nan, return_train_score=False)
```

1.estimator: Pass the model instance for which you want to check the hyperparameters.

2.params_grid: the dictionary object that holds the hyperparameters you want to try

3.scoring: evaluation metric that you want to use, you can simply pass a valid string/object of evaluation metric

4.cv: number of cross-validation you have to try for each selected set of hyperparameters

5.verbose: you can set it to 1 to get the detailed print out while you fit the data to GridSearchCV

6.n_jobs: number of processes you wish to run in parallel for this task if it -1 it will use all available processors.



GridSearchCV Results

```
import pandas as pd
 results = pd.DataFrame(grid.cv results )
 results.columns
Index(['mean fit time', 'mean score time', 'mean test score',
         'mean_train_score', 'param_n_neighbors', 'params', 'rank_test_score'
         'split0_test_score', 'split0_train_score', 'split1_test_score',
'split1_train_score', 'split2_test_score', 'split2_train_score',
         'split3_test_score', 'split3_train_score', 'split4_test_score',
         'split4_train_score', 'split5_test_score', 'split5_train_score',
'split6_test_score', 'split6_train_score', 'split7_test_score',
'split7_train_score', 'split8_test_score', 'split8_train_score',
         'split9_test_score', 'split9_train_score', 'std_fit_time',
         'std_score_time', 'std_test_score', 'std_train_score'],
        dtvpe='object')
 results.params
                                                                                               20/21
```

arisa

...

EVALUACIÓN DE MODELOS

(la métrica para GridSearch)



Límites de las métricas tradicionales ...

- LA PRECISIÓN SOLO DA UNA VISIÓN MUY PARCIAL DE LO QUE HACE UN CLASIFICADOR
- r**2 SOLO DA UNA VISIÓN MUY PARCIAL DE LO BUENA QUE ES LA APROXIMACIÓN DE UNA FUNCIÓN
- Es importante comprender la motivación detrás de estas métricas para comprender la información que proporcionan.
- Obtén información sobre cómo elegir la métrica correcta para seleccionar entre modelos o para ajustar parámetros.



Evaluación

Representación:

Extraer y
seleccionar
características de
objetos



Entrenar modelos:

Ajustar el
estimador a los
datos



Refinamiento

<u>de</u>

<u>característica</u>

<u>s y modelos</u>





- Diferentes aplicaciones tienen objetivos muy diferentes
- La precisión es ampliamente utilizada, pero muchas otras son posibles, por ejemplo:
 - Satisfacción del usuario (búsqueda web)
 - Cantidad de ingresos (comercio electrónico)
 - Aumento de las tasas de supervivencia de los pacientes (médico)



- Es muy importante elegir métodos de evaluación que coincidan con el objetivo de su solicitud.
- Calcule la métrica de evaluación seleccionada para varios modelos diferentes.
- A continuación, seleccione el modelo con el "mejor" valor de la métrica de evaluación.

Precisión con clases desequilibradas

- Supongamos que tienes dos clases:
 - Relevante (R): la clase positiva
 - No_Relevante (N): la clase negativa
 - De 1000 artículos seleccionados al azar, en promedio
 - Un artículo es relevante y tiene una etiqueta R
 - El resto de los artículos (999 de ellos) no son relevantes y están etiquetados como N. Recordemos que:
 - Accuracy = #correct predictions #total instances



Precisión con clases desequilibradas

- Crea un clasificador para predecir elementos relevantes y ve que su precisión en un conjunto de pruebas es del 99,9 %.
- A modo de comparación, supongamos que tuviéramos un clasificador "ficticio" que no mirara las características en absoluto, y siempre predijera ciegamente la clase más frecuente (es decir, la clase N negativa).



Precisión con clases desequilibradas

 Suponiendo un conjunto de prueba de 1000 instancias, ¿cuál sería la precisión de este clasificador ficticio? Respuesta:

• Accuracy_{DUMMY} = 999 / 1000 = 99.9%



Los clasificadores ficticios(dummy) ignoran los datos de entrada

- Los clasificadores ficticios sirven como control
- Proporcionan una línea de base de métrica nula (por ejemplo, precisión nula).
- Algunas configuraciones de uso común para el parámetro de estrategia para
- DummyClassifier en scikit-learn:
 - most_frequent : predicts the most frequent label
 - *stratified*: random predictions
 - uniform: generates predictions uniformly at random.
 - constant: always predicts a constant label provided by the user.



Resultados de predicciones binarias

True TN FP

Label 1 = positive class (class of interest)

Label 0 = negative class (everything else)

TP = true positive

FP = false positive (Type I error)

TN = true negative

FN = false negative (Type II error)

Predicted negative

Predicted positive



Confusion matrix for binary prediction task

N = 450

True negative

True positive

TN = 356	FP = 51
FN = 38	TP = 5

Predicted negative

Predicted positive

- Cada instancia de prueba está exactamente en un cuadro (recuentos de enteros).
- Desglosa los resultados del clasificador por tipo de error.
- Por lo tanto, proporciona más información que la simple precisión.
- Le ayuda a elegir una métrica de evaluación que coincida con los objetivos del proyecto.
- Ni un solo número como la precisión. Pero hay muchas métricas posibles que se pueden derivar de la matriz de confusión.



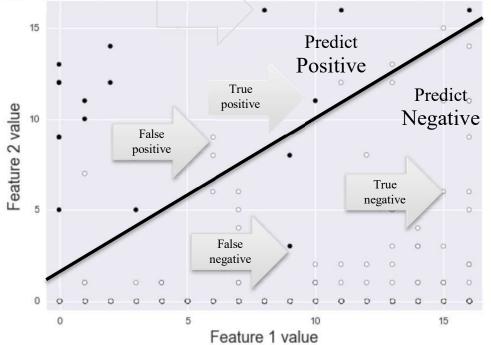
Binary (two-class) confusion matrix

```
[13]: from sklearn.metrics import confusion matrix
      # Negative class (0) is most frequent
      dummy majority = DummyClassifier(strategy = 'most frequent').fit(X train, y train)
      y majority predicted = dummy majority.predict(X test)
      confusion = confusion matrix(y test, y majority predicted)
      print('Most frequent class (dummy classifier)\n', confusion)
      Most frequent class (dummy classifier)
       [[407 0]
       [ 43 0]]
[14]: # produces random predictions w/ same class proportion as training set
      dummy classprop = DummyClassifier(strategy='stratified').fit(X train, y train)
      y classprop predicted = dummy classprop.predict(X test)
      confusion = confusion matrix(y test, y classprop predicted)
      print('Random class-proportional prediction (dummy classifier)\n', confusion)
      Random class-proportional prediction (dummy classifier)
       [[358 49]
       [ 41 2]]
```



Visualización de diferentes tipos de error





TN = 429	FP = 6
FN = 2	TP = 13



Precisión:

True negative	TN = 400	FP = 7		Accuracy = $\frac{TN+TP}{TN+TP+FN+FP}$ $= 400+26$
True positive	FN = 17	TP = 26		$= \frac{400 + 26 + 17 + 7}{400 + 26 + 17 + 7}$ $= 0.95$
	Predicted negative	Predicted positive	N=450	



Classification error (1 - Accuracy):

True negative

True positive

TN = 400	FP = 7	
FN = 17	TP = 26	
Predicted negative	Predicted positive	N = 450

ClassificationError = $\frac{FP + FN}{TN + TP + FN + FP}$

$$=\frac{7+17}{400+26+17+7}$$

$$= 0.060$$

Recall (sensibilidad/exhaustividad)

True negative

True positive

TN = 400	FP = 7	
FN = 17	TP = 26	
Predicted negative	Predicted positive	N=450

$$Recall = \frac{TP}{TP + FN}$$

$$= 0.60$$

26+17

Recall is also known as:

- True Positive Rate (TPR)
- Sensitivity
- Probability of detection



APPLIED MACHINE LEARNING IN PYTHON

Precision

True negative

True positive

TN = 400	FP = 7	
FN = 17	TP = 26	
Predicted negative	Predicted positive	N=450

$$Precision = \frac{TP}{TP+FP}$$
$$= \frac{26}{26+7}$$
$$= 0.79$$



False positive rate (FPR)

True	
negative	

True positive

TN = 400	FP = 7	
FN = 17	TP = 26	
		N. 450

$$FPR = \frac{FP}{TN + FP}$$

$$=\frac{7}{400+7}$$

$$= 0.02$$

Predicted negative

Predicted positive

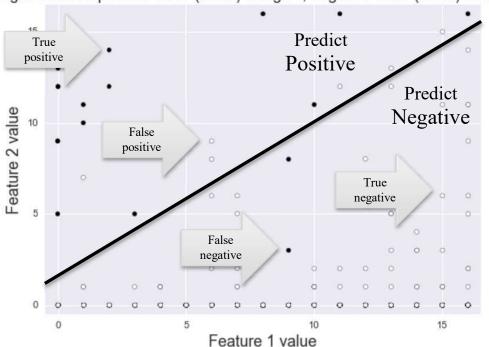
$$N = 450$$

False Positive Rate is also known as:

• Specificity

The Precision-Recall Tradeoff (sensibilidad vs. Precision)

digits dataset: positive class (black) is digit 1, negative class (white) all others



$$TN = 429$$
 $FP = 6$ $FN = 2$ $TP = 13$

Precision =
$$\frac{TP}{TP+FP} = \frac{13}{19} = 0.68$$

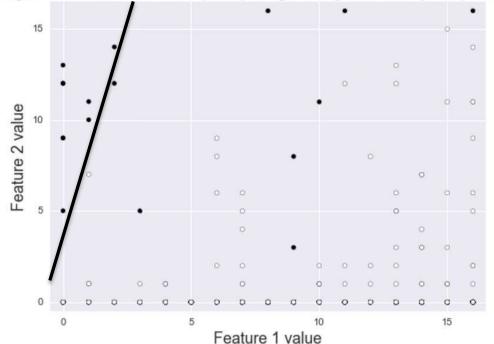
Recall = $\frac{TP}{TP+FN} = \frac{13}{15} = 0.87$



3

High Precision, Lower Recall





TN = 435	FP = 0
FN = 8	TP = 7

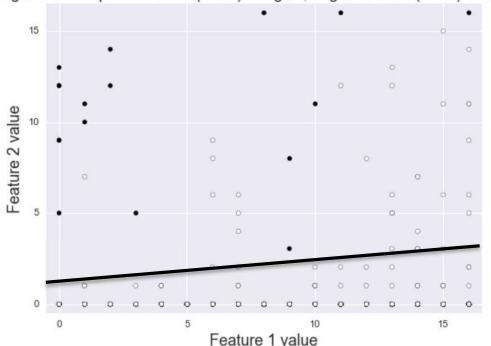
Precision =
$$\frac{TP}{TP+FP} = \frac{7}{7} = 1.00$$

Recall = $\frac{TP}{TP+FN} = \frac{7}{15} = 0.47$



Low Precision, High Recall





TN = 408	FP = 27
FN = 0	TP = 15

Precision =
$$\frac{TP}{TP+FP} = \frac{15}{42} = 0.36$$

Recall = $\frac{TP}{TP+FN} = \frac{15}{15} = 1.00$



Compensación entreprecision and recall

- Recall-oriented Tareas de aprendizaje automático:
 - Búsqueda y extracción de información en el descubrimiento legal
 - Detección de tumores
 - A menudo se combina con un experto humano para filtrar falsos positivos

Precision-oriented Tareas de aprendizaje automático:

- Clasificación en motores de búsqueda, sugerencia de consulta
- Clasificación de documentos
- Muchas tareas orientadas al cliente (¡los usuarios recuerdan los fracasos!)



F1-score: Combinando precisión y recuperación en un solo número

$$F_1 = 2 \cdot \frac{Precision \cdot Recall}{Precision + Recall} = \frac{2 \cdot TP}{2 \cdot TP + FN + FP}$$



F-score:

$$F_1 = 2 \cdot \frac{Precision \cdot Recall}{Precision + Recall} = \frac{2 \cdot TP}{2 \cdot TP + FN + FP}$$

$$F_{\beta} = (1 + \beta^2) \cdot \frac{Precision \cdot Recall}{(\beta^2 \cdot Precision) + Recall} = \frac{(1 + \beta^2) \cdot TP}{(1 + \beta^2) \cdot TP + \beta \cdot FN + FP}$$

 β allows adjustment of the metric to control the emphasis on recall vs precision:

- Precision-oriented users: $\beta = 0.5$ (false positives hurt performance more than false negatives)
- Recall-oriented users: $\beta = 2$ (false negatives hurt performance more than false positives)



```
from sklearn.metrics import accuracy score, precision score, recall score, fl score
print('Accuracy: {:.2f}'.format(accuracy score(y test, tree predicted)))
print('Precision: {:.2f}'.format(precision score(y test, tree predicted)))
print('Recall: {:.2f}'.format(recall score(y test, tree predicted)))
print('F1: {:.2f}'.format(f1 score(y test, tree predicted)))
Accuracy: 0.95
Precision: 0.79
Recall: 0.60
F1: 0.68
from sklearn.metrics import classification report
print(classification_report(y test, tree_predicted, target_names=['not 1', '1']))
            precision
                        recall f1-score
                                           support
                 0.96
                          0.98
                                    0.97
                                              407
     not 1
                 0.79
                          0.60
         1
                                    0.68
                                               43
avg / total
                 0.94
                          0.95
                                    0.94
                                              450
```



```
]: print('Random class-proportional (dummy)\n',
        classification report(y test, y classprop predicted, target names=['not 1', '1']))
   print('SVM\n',
        classification report(y test, svm predicted, target names = ['not 1', '1']))
   print('Logistic regression\n',
        classification report(y test, lr predicted, target names = ['not 1', '1']))
   print('Decision tree\n',
        classification_report(y_test, tree_predicted, target_names = ['not 1', '1']))
   Random class-proportional (dummy)
                precision
                             recall f1-score
                                               support
        not 1
                    0.91
                              0.94
                                        0.92
                                                  407
                    0.19
                              0.14
            1
                                        0.16
                                                   43
   avg / total
                              0.86
                    0.84
                                       0.85
                                                  450
   SVM
                precision
                             recall f1-score
                                               support
        not 1
                    0.99
                              0.99
                                        0.99
                                                  407
                    0.88
                              0.88
                                       0.88
            1
                                                   43
```



Parámetros de búsqueda de cuadrícula (Grid Search Parameters)

```
sklearn.model_selection.GridSearchCV(estimator, param_grid,scoring=None, n_jobs=None, iid='deprecated', refit=True, cv=None, verbose=0, pre_dispatch='2*n_jobs', error_score=nan, return_train_score=False)
```

1.estimator: Pass the model instance for which you want to check the hyperparameters.

2.params_grid: the dictionary object that holds the hyperparameters you want to try

3.scoring: evaluation metric that you want to use, you can simply pass a valid string/object of evaluation metric

4.cv: number of cross-validation you have to try for each selected set of hyperparameters 5.verbose: you can set it to 1 to get the detailed print out while you fit the data to GridSearchCV 6.n_jobs: number of processes you wish to run in parallel for this task if it -1 it will use all available processors.



BUILDING A MACHINE LEARNING MODEL SUMMARY

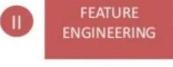
Pulsa Esc para salir del modo de pantalla completa



First, you will apply some of the most common data cleaning actions on your **raw data**, including **removing outliers** and dealing with **missing values** and **categorical variables**.



You then **turn raw data into individual measurable properties (features)** that will help your model complete its task. They must be as **informative**, **discriminative** and **non-redundant** as possible. This step is **commonly acknowledged as the most important part** in building a ML model.



1

DATA MODELING

You can now apply either **supervised or unsupervised** machine learning algorithms. Their **complexity vary** but how they correctly model your data will **solely depend on your assumptions**.



IV PERFORMANCE MEASURE To assess the performance of your model, you will pick a **relevant indicator that you understand** and measure it on **unseen test data** that you will **have set aside before training your model**.



IMPROVEMENT

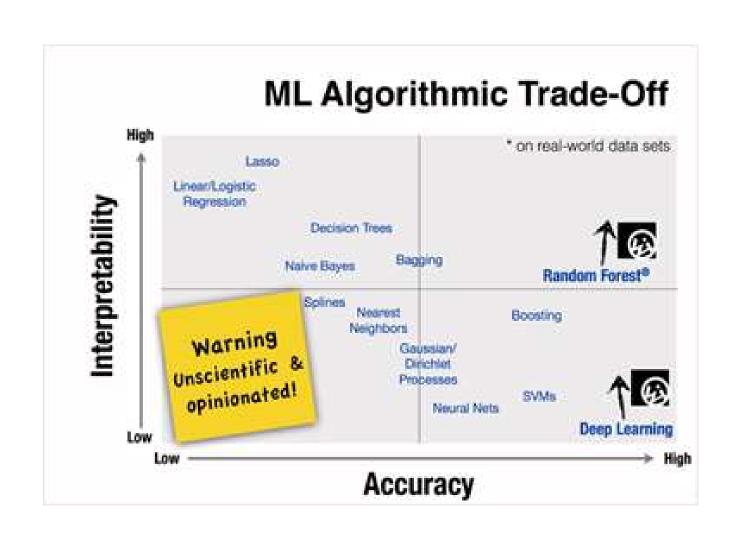
Your model can underperform for **only two reasons: underfitting or overfitting**. Many solutions exist, including two popular techniques: **regularization** (overfitting) and **boosting** (underfitting.)

Machine Learning Algorithms Cheat Sheet



ESTRATEGIA GENERAL

- Decidir la métrica
- Cuando se trabaja con un nuevo conjunto de datos, en general es una buena idea comenzar con un modelo simple, como un modelo lineal, Bayes o K-nn y ver hasta dónde puede llegar. Después de comprender más sobre los datos, puede considerar pasar a un algoritmo que pueda crear modelos más complejos, como bosques aleatorios, XGBoost, SVM para acabar redes neuronales/deep learning.
- La mayoría de los algoritmos presentados anteriormente tienen variantes de clasificación y regresión, y todos los algoritmos de clasificación admiten la clasificación binaria y multiclase.



Cuando aplicar los modelos

- K Vecinos más cercanos: para conjuntos de datos pequeños, buenos como línea de base, fáciles de explicar.
- **Modelos lineales**: Opta como primer algoritmo a probar, bueno para conjuntos de datos muy grandes, bueno para datos de muy alta dimensión.
- Árboles de decisión: Muy rápidos, no necesitan escalado de los datos, se pueden visualizar y explicar fácilmente.
- **Bosques aleatorios**: Casi siempre se comportan mejor que un solo árbol de decisión, muy robustos y potentes. No es necesario escalar los datos. No es bueno para datos dispersos de dimensiones muy altas.
- Árboles de decisión potenciados por gradiente (Gradient bossted decisión tres): a menudo son ligeramente más precisos que los bosques aleatorios. Más lento de entrenar, pero más rápido de predecir que el bosque aleatorio y más pequeño en memoria. Necesita más ajuste de parámetros que el bosque aleatorio.
- Máquinas vectoriales de soporte: Potente para conjuntos de datos de tamaño mediano de características con significado similar. Necesita escalado de datos, sensible a los parámetros.
- NN/DL: Grandes cantidades de datos, costosos, nula explicabilidad, buenos resultados.









www aiskills eu